

모델1 · g2-si-speed-s201 — 최종 추천 모델

scratch-initscale의 완성 정책에 speed shaping을 파인튜닝으로 얹어, 해결률과 낙상률을 동시에 개선한 최종 추천 모델.

체크포인트 ep794 해결 시점 파인튜닝 794ep (부모 포함 총 3875ep) 작성일 2026-07-11

✓ 안정성 우선 최종 추천 후보

5개 완주 모델 중 낙상률이 12%로 가장 낮습니다(모델2 대비 18%→12%, 100개 중 6 episode 차이). 해결률(83%)도 5개 중 가장 높지만 모델2(82%)와의 차이는 100개 중 1 episode에 불과해 통계적으로 확정된 우위라고는 말하지 않습니다. scratch-initscale의 완성 정책(모델2)에 speed shaping 하나만 얹어 794 에피소드만 더 학습한 파인튜닝 모델로, "이미 잘 걷는 정책을 어떻게 더 안정적으로 다듬을 것인가"라는 질문에 대한 답입니다. 모든 지표에서 절대적으로 최고는 아니며, 클리어 속도는 5개 중 가장 느립니다 — 최종 선정 이유는 최고 해결률 자체보다 가장 낮은 낙상률과 실제 데모 안정성입니다.

1 State · Action · Reward 설계

본 모델은 부모 모델(scratch-initscale)의 State/Action 설계를 그대로 물려받고, Reward 설계만 한 겹 더 추가했습니다.

State(24차원): 몸통 각도·각속도, x/y 속도, 양다리 고관절·무릎 각도 및 각속도(4관절×2), 양발 지면 접촉 플래그(2), 전방 지형을 감지하는 라이다 10개.

Action(4차원, [-1,1] 연속값): 양다리 고관절·무릎 모터 토크. Actor 출력층에 Tanh를 적용해 범위를 강제합니다.

Reward: Gymnasium 기본 보상(전진 거리 비례 + 모터 사용 패널티)에 3개 래퍼를 순서대로 적용 — ① frame_skip=2(행동을 2스텝 반복·보상 합산, 결정을 더 굵은 시간 단위로 만들어 학습을 단순화), ② fall_penalty=-10(원래 -100인 낙상 패널티를 완화해 과감한 탐험 유도), ③ speed shaping(매 스텝 전진속도(obs[2])가 0.3 이상이면 +0.03 보너스, 0.05 미만이면 -0.02 패널티 — 이 모델만의 추가 신호).

2 설정 근거 & 반복 개선 로드맵

이 모델의 이야기는 부모 모델(scratch-initscale, 모델2)이 이미 hardcore를 풀어낸 이후, "완주는 하지만 가끔 넘어진다"는 잔여 문제에서 시작합니다.

STEP 0 · 출발점

부모 모델(scratch-initscale)이 ep3081에 avg100=300.13으로 해결

init_scale=0.003 + critic_output_scale=10만으로 hardcore를 처음 해결한 모델(모델2 참고). 다만 이후 100에피소드 헤드리스 재평가에서 **낙상률 18%**가 확인됨 — 다섯 번 중 한 번 꼴로 완주 도중 넘어짐.

PROBLEM

"완주 vs 낙상"의 이분법 — 저속·불안정 구간에서 회복 신호 부재

기존 보상 구조는 전진 거리에 비례한 보상만 있을 뿐, "지금 자세가 불안정하다"는 것을 정책이 사전에 인지하도록 만드는 직접적 신호가 없습니다. 대화 중 팀이 제기했던 문제의식과 같은 결: 낙상 패널티를 낮게 유지하면(과감한 탐험에는 유리하지만) 정책이 "가끔 넘어져도 큰 손해가 아니다"라고 학습할 여지가 남습니다. scratch-initscale의 18% 낙상률이 바로 그 여지가 실현된 사례로 해석됩니다.

FIX

Speed Shaping 래퍼를 파인튜닝 단계에서 추가

매 스텝마다 "일정 속도 이상을 유지하고 있는가"를 조건부로 확인해 보너스/패널티를 부여하는 래퍼를 부모 체크포인트(ep3081)에 이어 붙였습니다. 핵심은 **한 번의 순간적인 가속이 아니라 지속적인 속도 유지를 요구한다는 점** — burst-then-coast(잠깐 빨리 걷고 나머지는 대충 버티는) 형태의 보상 해킹을 원천적으로 방지하도록 설계했습니다. 794 에피소드 만에 avg100 300.71로 재수렴.

RESULT

100ep 재평가: 낙상률 18%→12%, 해결률 82%→83%

낙상률 개선은 6 episode 차이로 뚜렷하지만, 해결률 개선(82%→83%)은 1 episode 차이로 통계적으로 확정된 우위라고 말하지 않습니다. 비낙상 표준편차도 2.44→2.83으로 소폭 상승했지만 (아래 표3 참고), 낙상률 개선폭을 더 중요하게 판단해 안정성 우선 최종 추천 후보로 선정했습니다.

3 학습 곡선 (파인튜닝 794 에피소드)

x축은 이 run 자체의 에피소드 카운터(0부터 시작)입니다 — **--resume**은 가중치만 이어받고 옵티마이저 상태와 리플레이 버퍼는 새로 시작하기 때문에, 초반 수십 에피소드 동안 일시적으로 보상이 흔들리는 구간이 관찰됩니다(그래프에서 확인 가능).

Reward Curve — g2-si-speed-s201 (파인튜닝 구간)

794 에피소드, 최종 avg100=300.71, 최고 avg100=300.71

4 100 에피소드 헤드리스 재평가

noise_std=0, 고정 시드 9000–9099. frame_skip=2·fall_penalty=-10 래퍼는 유지한 채 speed-shaping 보너스만 제외한 wrapper reward 기준입니다(순수 Gymnasium 원점수 아님, 공정 비교를 위해 전 모델 통일). "클리어 스텝"은 frame_skip=2 적용 후의 decision step입니다.

지표(100EP 헤드리스, NOISE=0, 세이핑 보너스 제외)	값
전체 평균 보상	286.6
비낙상 평균 보상	304.73
비낙상 표준편차	2.83
해결률 (reward≥300)	83.0%
낙상률	12.0%
비낙상 평균 클리어 스텝	502.6

5 안정성 분석 — 왜 낙상률이 가장 낮은가

모든 주장은 위 100ep 데이터 및 학습 곡선 관찰에 근거합니다.

주장 1 — 비낙상 표준편차(2.83)가 낮지만 부모(2.44)보다는 높다: speed shaping이 "일정 리듬의 보행 패턴"을 학습하도록 유도하는 것은 맞지만, 매 스텝 조건부 보상이라는 특성상 정책이 그 조건(0.3 이상 유지)에 딱 맞춰 최적화되면서 완주 시점의 최종 보상 자체는 부모보다 살짝 더 넓게 퍼집니다(304.73 vs 310.96) — "안정적으로 완주"와 "완주 시 점수가 항상 똑같음"은 서로 다른 축이라는 근거입니다.

주장 2 — 낙상률이 18%→12%로 실제로 줄었다(관측된 사실): speed shaping의 패널티(-0.02)는 저속 구간, 즉 넘어지기 직전 흔히 나타나는 "휘청이며 속도가 죽는" 상태에 대해 매 스텝 벌점을 줍니다. "이 패널티가 정책을 위태로운 저속 상태에서 벗어나도록 압력을 줘 회복 실패 빈도를 낮췄다"는 것은 **가능한 메커니즘(가설)**입니다 — 낙상 직전 구간의 속도·자세 trajectory를 직접 분석하지는 않았으므로, 관측된 사실은 낙상률이 줄었다는 것이고 그 원인 설명은 후속 분석이 필요합니다.

주장 3 — 클리어 속도(502.6 스텝)가 5개 중 가장 느리다(유일한 약점): "안정성"을 우선한 보상 신호가 "빠르게 걷기"보다 "일정한 리듬을 지키는 안전한 보폭"을 선호하는 정책으로 수렴시켰을 가능성이 있습니다. 안정성과 속도가 트레이드오프 관계에 있다는 근거로, 5개 모델 비교표(총 보고서 참고)에서도 동일한 패턴(낙상률이 낮을수록 클리어 속도가 느려지는 경향)이 관찰됩니다.

6 재현 방법

전제조건

학습 재현 `python3 Bipedalwalker_TD3_live.py --resume --ckpt ep3081 --set run_tag=g2-`

로컬 재생