

모델2 · scratch-initscale — 최소 복잡도 차선택

LayerNorm·speed shaping 없이 출력층 초기화 스케일과 Critic 출력 스케일링만으로 hardcore를 처음 해결한 모델. 걸음 품질 1위.

체크포인트 ep3081 해결 시점 from scratch 3081ep 작성일 2026-07-11

차선택 · 최소 복잡도

LayerNorm도, speed shaping도 없이 **출력층 초기화 스케일 + Critic 출력 스케일링**이라는 단 두 가지 트릭만으로 처음부터(from scratch) hardcore를 해결한 모델입니다. 5개 모델 중 **비낙상 평균 보상(310.96)**과 **표준편차(2.44)** 모두 **1위** — "완주만 하면 가장 잘 걷는" 모델입니다.

1 State · Action · Reward 설계

State(24차원): 몸통 각도·각속도, x/y 속도, 양다리 관절 각도/각속도(8), 발 접촉(2), 라이다(10).

Action(4차원, [-1,1]): 양다리 고관절·무릎 토크.

Reward: Gymnasium 기본 보상 + $\text{frame_skip}=2(\text{행동 반복}\cdot\text{보상 합산}) + \text{fall_penalty}=-10(\text{낙상 시 } -100 \text{ 대신 } -10 \text{으로 완화})$. **speed shaping은 사용하지 않음** — 환경이 주는 순수 신호만으로 학습.

2 설정 근거 & 반복 개선 로드맵

이 모델은 hardcore 환경에서 학습이 전혀 수렴하지 않던 초기 국면을 벗어나기 위한 첫 성공 사례입니다.

PROBLEM 1

Hardcore 전환 직후 학습이 수렴하지 않음

Flat(비-hardcore) 환경에서는 정상적으로 학습되던 기존 TD3 파이프라인을 hardcore로 그대로 옮기자 평균 보상이 장기간 정체·발산했습니다. hardcore는 계단·구덩이·그루터기 등 지형이 procedurally 생성되어 원본 대비 훨씬 sparse하

고 가혹한 -100 낙상 패널티를 가지고 있어, 초반 탐험 단계에서 에이전트가 "무엇을 해도 크게 벌점을 받는다"는 신호만 반복적으로 받는 것이 원인으로 진단되었습니다.

FIX 1

외부 사례 리서치 → **frame_skip + fall_penalty** 완화 도입

hardcore를 성공적으로 푼 타 구현체(td3-sac-bipedal-walker-hardcore-v3)를 분석해 **frame_skip=2** (의사결정 빈도를 낮춰 학습을 단순화)와 **fall_penalty=-10**(원래 -100인 낙상 벌점을 완화해 과감한 탐험을 허용) 두 가지를 Config에 opt-in 옵션으로 추가했습니다. 이 두 가지만으로 학습이 눈에 띄게 안정화됐지만, 여전히 300점 solve 기준에는 도달하지 못하는 정체 구간이 남아있었습니다.

PROBLEM 2

frame_skip+fall_penalty만으로는 300점 근처에서 정체

Critic이 상태-행동 가치(Q)를 정확히 추정하지 못해 Actor가 잘못된 방향으로 유도되는 정황이 관찰되었습니다. 원인으로 지목된 것은 신경망 출력층의 기본 초기화 — PyTorch의 기본 Linear 층 초기화는 출력이 대체로 $[-1, 1]$ 근방에 머무는데, 이 태스크의 목표 Q값 스케일(누적 보상 300+)과는 자릿수가 다릅니다. Critic이 이 큰 격차를 좁히는 데만 많은 스텝을 소모하며 학습 초반이 비효율적으로 흘러가는 것으로 추정했습니다.

FIX 2

critic_output_scale=10 + final_layer_init_scale=0.003 도입

critic_output_scale($\times 10$)은 Critic 최종층 출력에 곱해지는 스케일 팩터로, 초기 Q값 추정 범위를 목표 스케일에 더 가깝게 맞춰줍니다. **final_layer_init_scale(± 0.003)**은 Actor/Critic 최종층의 가중치를 매우 작은 값으로 초기화(및 bias 제거)해 학습 초반 정책이 극단적인 행동을 내지 않고 보수적으로 시작하도록 만드는, DDPG/TD3 계열에서 흔히 쓰이는 안정화 관례입니다. 이 두 가지를 결합해 처음부터(from scratch) 다시 학습한 결과, **ep3081에서 avg100=300.13**으로 hardcore를 처음으로 해결했습니다. 다만 **critic_output_scale**과 **final_layer_init_scale**을 각각 단독으로 켜고 끈 ablation은 수행하지 않았으므로, 두 트릭의 개별 기여도는 분리할 수 없고 **조합 효과로만 해석**합니다.

3 학습 곡선 (from scratch, 3081 에피소드 전체)

Reward Curve — scratch-initscale (전체 학습)

3081 에피소드, 최종 avg100=300.13

— episode reward(원시) — avg_reward_100(이동평균) - - - solve 기준선(300)

그래프에서 확인 가능한 특징: 초반 500ep까지는 원시 보상(연한 선)의 변동폭이 매우 크다가(탐험 노이즈가 높은 구간, noise_std_start=0.3), 이후 노이즈가 감소(noise_decay_episodes=800)하면서 avg100(굵은 선)이 완만하게 300을 향해 수렴합니다.

4 100 에피소드 헤드리스 재평가

noise_std=0, 고정 시드 9000–9099. frame_skip=2·fall_penalty=-10 래퍼는 유지한 채 speed-shaping 보너스만 제외한 wrapper reward 기준입니다(순수 Gymnasium 원점수 아님). "클리어 스텝"은 frame_skip=2 적용 후의 decision step입니다.

지표(100EP 헤드리스, NOISE=0, 세이핑 보너스 제외)	값
전체 평균 보상	285.35
비낙상 평균 보상	310.96
비낙상 표준편차	2.44
해결률 (reward≥300)	82.0%
낙상률	18.0%
비낙상 평균 클리어 스텝	482.3

5 안정성 분석 — 왜 걸음 품질이 가장 좋은가

주장 1 — 비낙상 평균(310.96)·표준편차(2.44) 모두 5개 중 최고: 이 모델에는 speed shaping 같은 보조 신호가 전혀 없습니다. 즉 정책이 인위적인 중간 목표(속도 유지 등)에 맞춰 타협하지 않고, **환경이 실제로 원하는 목표(빠르고 정확하게 끝까지 도달)를 직접 최적화**한 결과로 해석합니다. 보조 신호가 정책을 특정 방향으로 유도하는 동시에 순수 목표로부터 미세하게 이탈시킬 수 있다는 근거이며, 모델3(fulltrick-speed, 트릭을 더 넣었지만 비낙상 평균이 307.20으로 더 낮음)과의 비교가 이를 뒷받침합니다.

주장 2 — 그럼에도 낙상률(18%)은 g2-si-speed-s201(12%)보다 높다: 보조 신호가 없다 보니 "위태로운 저속 구간에서 스스로 회복하라"는 명시적 유인이 없습니다. 이는 모델1(파인튜닝으로 speed shaping을 추가해 낙상률을 12%까지 낮춘 사례)이 실증적으로 뒷받침하는 대조 사례입니다 — 즉 이 모델의 18% 낙상률은 "순수 신호만으로는 못 잡아내는 잔여 리스크"로 해석할 수 있습니다.

주장 3 — 클리어 속도(482.3 스텝)가 5개 중 2위로 빠르다: BipedalWalker의 기본 보상은 전진 거리에 비례하고 모터 사용에 소량의 패널티를 부과하는 구조라, 정책이 최적화를 거듭할수록 "불필요하게 느리게 걷는 것" 자체가 손해이므로 자연스럽게 효율적인 속도로 수렴하는 경향이 있습니다. 별도의 속도 유인 없이도 2위를 기록한 것이 그 근거입니다.

6 재현 방법

학습 재현 `python3 Bipedalwalker_TD3_live.py --set run_tag=scratch-initscale hardcore:`
로컬 재생

