

모델3 · scratch-fulltrick-speed — 클리어 속도 1위

알려진 안정화 트릭을 전부 동시에 적용한 모델. 클리어 속도는 1위지만 해결률·낙상률은 더 단순한 모델2보다 낮은 반례 사례.

체크포인트 ep2778 해결 시점 from scratch 2778ep 작성일 2026-07-11

클리어 속도 1위 · 반례 사례

당시 알려진 안정화 트릭(LayerNorm, 초기화 스케일, Critic 스케일, speed shaping)을 모두 동시에 적용해 "트릭을 더 많이 넣을수록 더 좋아질 것"이라는 가설을 검증한 모델입니다. 결과적으로 클리어 속도는 5개 중 1위(477.0스텝)를 기록했지만, 해결률·낙상률은 더 단순한 모델2보다 오히려 낮아 "트릭이 많다고 항상 좋아지는 것은 아니다"라는 중요한 반례가 되었습니다.

1 State · Action · Reward 설계

State/Action: 모델2와 동일(24차원 관측, 4차원 연속 토크).

Reward: frame_skip=2 + fall_penalty=-10 + **speed shaping(low=0.05 high=0.3 penalty=-0.02 bonus=0.03)**
을 학습 시작부터 포함. 모델1(g2-si-speed-s201)이 "완성된 정책에 나중에 speed shaping을 붙인" 경우라면, 이 모델은 "처음부터 speed shaping을 켜고 학습한" 경우라는 점이 핵심적인 차이입니다.

2 설정 근거 & 반복 개선 로드맵

모델2(scratch-initscale)와 거의 동시에 시작된 "최대 트릭 투입" 실험입니다.

STEP 0 · 가설

"안정화 트릭을 더 많이 넣으면 더 안정적이지 않을까?"

모델2가 init_scale+critic_scale 두 가지만으로 hardcore를 해결하기 시작한 시점에, 대조군으로 LayerNorm과 speed shaping까지 추가로 넣은 "풀 트릭" 버전을 병행 실행했습니다.

RESULT 1

ep2778에 해결 — 모델2보다 오히려 300ep 더 빠르게 수렴

avg100=301.61로 모델2(ep3081)보다 이른 시점에 solve 조건을 충족했습니다. 트릭을 더 넣은 것이 수렴 속도 자체에는 도움이 된 것으로 보입니다.

PROBLEM

100ep 재평가 결과, 오히려 모델2보다 해결률·걸음 품질이 낮음

해결률 80%(모델2 82%), 낙상률 18%(모델2와 동률), 비낙상 평균 307.20(모델2 310.96) — 트릭을 더 넣었음에도 최종 완성도 지표에서는 더 단순한 레시피에 밀렸습니다. 다만 이 차이를 LayerNorm 하나에 귀속할 수는 없습니다 — speed shaping 유무, random seed, replay trajectory, 학습 종료 시점이 모두 동시에 다르기 때문입니다. 안전한 결론은 "추가 트릭 조합이 수렴 속도에는 유리했으나 최종 정책 품질을 보장하지는 않았다"입니다.

INTERPRETATION

LayerNorm의 기대효과 vs 실측 한계효용

LayerNorm은 은닉층 출력을 정규화해 정책이 급격히 바뀔 때 발생하는 activation distribution shift를 완화하는 것이 이론적 기대 효과입니다. 그러나 이 태스크에서는 이미 init_scale+critic_scale 만으로 충분히 안정적인 학습이 가능했기에 LayerNorm이 추가로 기여할 여지가 크지 않았고, 정규화 과정에서 은닉 표현이 일부 압축되며 최종 정책의 미세한 품질(비낙상 평균 보상)을 오히려 소폭 낮췄을 가능성이 있습니다 — "트릭 추가에는 한계효용 체감이 있다"는 해석의 근거로 총 보고서에도 반영했습니다.

3 학습 곡선 (from scratch, 2778 에피소드 전체)

Reward Curve — scratch-fulltrick-speed (전체 학습)

2778 에피소드, 최종 avg100=301.61

— episode reward(원시) — avg_reward_100(이동평균) - - - solve 기준선(300)

4 100 에피소드 헤드리스 재평가

noise_std=0, 고정 시드 9000–9099. frame_skip=2·fall_penalty=-10 래퍼는 유지한 채 speed-shaping 보너스만 제외한 wrapper reward 기준입니다(순수 Gymnasium 원점수 아님). "클리어 스텝"은 frame_skip=2 적용 후의 decision step입니다.

지표(100EP 헤드리스, NOISE=0, 세이핑 보너스 제외)	값
전체 평균 보상	282.97
비낙상 평균 보상	307.2
비낙상 표준편차	3.66
해결률 (reward≥300)	80.0%
낙상률	18.0%
비낙상 평균 클리어 스텝	477.0

5 안정성 분석 — 왜 클리어 속도만큼은 1위인가

주장 1 — 클리어 속도(477.0스텝)가 5개 중 최고인 이유: speed shaping을 학습 시작부터 포함시켰기 때문에, 정책 자체가 처음부터 "일정 속도 이상을 유지해야 이득"이라는 구조 위에서 형성됐습니다. 반면 모델1(g2-si-speed-s201)은 이미 완성된 (느긋한 걸음걸이가 굳어진) 정책 위에 파인튜닝으로만 speed shaping을 엮었기 때문에 근본적인 보행 패턴을 바꾸기보다 미세 조정에 그쳤을 가능성이 있고, 실제로 클리어 속도는 오히려 더 느립니다(502.6스텝). "언제 보상 신호를 넣느냐"가 "무엇을 넣느냐"만큼 중요하다는 대조 근거입니다.

주장 2 — 그럼에도 해결률·낙상률은 모델2보다 낮다: LayerNorm으로 인한 표현력 제약(위 해석 참고)과, speed shaping이 처음부터 걸려 있어 정책이 "속도 조건 충족"과 "안전한 완주"라는 두 목표를 동시에 만족시켜야 하는 제약 하에서 학습됐다는 점이 복합적으로 작용한 것으로 추정합니다. 트릭이 많을수록 최적화해야 할 목표가 늘어나 특정 지표(순수 완주 안정성)에서는 손해를 볼 수 있다는 근거로 해석합니다.

6 재현 방법

학습 재현 `python3 Bipedalwalker_TD3_live.py --set run_tag=scratch-fulltrick-speed ha`
로컬 재생