

모델4 · new-speed-s102 — 최소 구성, 재현성 미검증

안정화 트릭 없이 speed shaping만으로 학습한 최소 구성 모델. 학습 중 최속 수렴을 보였지만
공정 재평가·재현 실험에서 약점이 드러남.

체크포인트 ep1556 해결 시점 from scratch 1556ep(학습 중 기준) 작성일 2026-07-11

학습 비용 최저 · 재현성 미검증(주의)

LayerNorm·초기화 스케일·Critic 스케일을 전혀 쓰지 않고 speed shaping 하나만 넣은 최소 구성 모델입니다. 학습 중 **1556 에피소드** 만에 **solve** 판정을 받아 지금까지 중 가장 빠른 기록을 세웠지만, 이후 두 가지 중요한 문제가 발견되어 배포용으로는 신중한 접근이 필요합니다.

1 State · Action · Reward 설계

State/Action: 모델2와 동일(24차원 관측, 4차원 연속 토크).

Reward: frame_skip=2 + fall_penalty=-10 + speed shaping(low=0.05 high=0.3 penalty=-0.02 bonus=0.03)만 사용. **init_scale**, **critic_output_scale**, **LayerNorm**은 전부 기본값(미사용) — 지금까지 나온 모델 중 아키텍처적으로 가장 단순합니다.

2 설정 근거 & 반복 개선 로드맵

"안정화 트릭 없이 speed shaping만으로도 될까?"라는 대조군 질문에서 출발한 모델이며, 두 차례의 중요한 문제 발견 과정을 거쳤습니다.



STEP 0 · 가설

아키텍처 트릭 없이 reward shaping만으로 수렴 가능한가?

모델2/3이 안정화 트릭으로 hardcore를 해결한 뒤, "그 트릭들이 정말 필수적인가, 아니면 reward shaping만으로도 충분한가"를 가리기 위한 4그룹 팩토리얼 실험(resume 여부 x speed shaping 여부)의 한 갈래로 시작했습니다.

RESULT

ep1556에 학습 중 solve 판정 — 지금까지 최속 기록

avg100(학습 중 롤링 평균, speed shaping 보너스 포함)이 1556 에피소드 만에 300을 넘었습니다. 모델2(3081ep), 모델3(2778ep)보다 훨씬 빠른 수렴이며, 한때 "가장 효율적인 레시피"로 보였습니다.

PROBLEM 1

평가 방법론 버그 — 학습 중 solve 기준이 셰이핑 보상 포함치였음

다른 4개 모델의 100ep 재평가는 speed shaping 보너스만 끈 wrapper reward 기준으로 측정됐는데 (frame_skip=2·fall_penalty=-10 래퍼는 유지, 순수 Gymnasium 원점수 아님), 이 모델을 처음 평가할 때 실수로 speed shaping을 켜 채로 측정해 해결률이 82%로 부풀려졌습니다. 셰이핑을 꺼서 공정하게 재측정한 결과 **해결률이 67%로 급락** — 5개 모델 중 가장 낮은 수치였습니다. "학습에 쓴 shaped reward"와 "실제 평가 기준(wrapper reward)"이 다르면, 학습이 빨리 끝난 것처럼 보여도 진짜 완성도는 다를 수 있다는 방법론적 교훈입니다.

PROBLEM 2

재현 실험 실패 — 동일 레시피, 다른 시드가 2000ep 넘도록 수렴 못함

동일한 설정에 시드만 바꾼 재현 실험(g2-ns-replicate-s601)을 병행 실행한 결과, 2000 에피소드가 넘도록 avg100이 150 근처에서 정체되어 전혀 수렴하지 못했습니다. 이는 이 모델의 **1556ep 초고속 수렴이 이 시드에서만 우연히 일어난 현상("시드 운")일 가능성**을 시사합니다 — 안정화 트릭(init_scale, critic_output_scale) 없이 학습을 시작하면 Critic의 초기 Q값 추정 정확도가 시드에 따라 크게 달라지고, 그 편차가 그대로 수렴 속도의 편차로 이어졌을 것으로 추정합니다.

3 학습 곡선 (from scratch, 1556 에피소드 전체)

Reward Curve — new-speed-s102 (전체 학습)

1556 에피소드, 최종 avg100=300.51 (셰이핑 포함 학습 중 기록)

— episode reward(원시) — avg_reward_100(이동평균) - - - solve 기준선(300)

참고: 이 그래프의 avg100은 학습 당시 기준(speed shaping 보너스 포함)이며, 아래 4번 표의 100ep 재평가 수치(셰이핑 제외)와는 척도가 다릅니다 — 그래프가 "빠른 수렴처럼 보이는" 이유가 바로 이 지점입니다.

4 100 에피소드 헤드리스 재평가 (공정 비교, 셰이핑 제외)

noise_std=0, 고정 시드 9000–9099. frame_skip=2·fall_penalty=-10 래퍼는 유지한 채 speed-shaping 보너스만 제외한 wrapper reward 기준입니다. "클리어 스텝"은 frame_skip=2 적용 후의 decision step입니다.

지표(100EP 헤드리스, NOISE=0, 세이핑 보너스 제외)	값
전체 평균 보상	275.97
비낙상 평균 보상	303.21
비낙상 표준편차	3.6
해결률 (reward≥300)	67.0%
낙상률	19.0%
비낙상 평균 클리어 스텝	492.9

5 안정성 분석 — 왜 재현성이 떨어지는가

주장 1 — 비낙상 표준편차(3.60)는 아주 나쁘지는 않다: 아키텍처 안정화 트릭이 전혀 없는데도 완주 시 점수 편차 자체는 5개 중 중간 수준입니다. speed shaping이 매 스텝 조건부 보상이라는 특성상 어느 정도 암묵적인 정규화 역할(그라디언트 분산을 줄이는 효과)을 했을 가능성이 있습니다.

주장 2 — 그러나 해결률(67%)이 5개 중 최저다: init_scale/critic_output_scale 같은 초기화 단계의 안정화 장치가 없다 보니, 학습 초반 Critic이 Q값을 부정확하게 추정하는 구간이 시드에 따라 들쭉날쭉했을 것으로 추정됩니다. 재현 실험(g2-ns-replicate-s601)의 실패가 이 해석을 뒷받침하는 직접적 근거입니다.

주장 3 — 배포 권고: 학습 비용(에피소드 수)만 보면 가장 매력적이지만, 공정 재평가에서 가장 약하고 재현성도 검증되지 않았습니다. 참고/실험 비교용으로는 가치가 있으나 최종 배포 후보로는 권장하지 않습니다.

6 재현 방법

학습 재현	<code>python3 Bipedalwalker_TD3_live.py --set run_tag=new-speed-s102 hardcore=True</code>
주의	
로컬 재생	

