

모델5 · g2-si-fastclear-s501 — 반면교사 사례

빠른 클리어를 노리고 speed shaping을 공격적으로 강화했으나, 해결률·낙상률·클리어 속도 세 지표 모두 최악을 기록한 반면교사 사례.

체크포인트 ep843 해결 시점(학습 중 기준) 파인튜닝 843ep 작성일 2026-07-11

△ 참고용 · 배포 비권장(반면교사 사례)

"빨리 클리어 + 안정성" 이중 목표가 도입된 후, 모델2(scratch-initscale)를 기반으로 speed shaping 강도를 의도적으로 공격적으로 조정해 더 빠른 완주를 노린 파인튜닝입니다. 학습 중에는 solve 판정($\text{avg100}=302.46$)까지 받았지만, 100ep 재평가에서 해결률·낙상률·클리어 속도 세 지표 모두 5개 중 최악으로 드러난 중요한 반면교사 사례입니다.

1 State · Action · Reward 설계

State/Action: 모델1과 동일(부모가 같은 scratch-initscale ep3081).

Reward: $\text{frame_skip}=2 + \text{fall_penalty}=-10 + \text{공격형 speed shaping (low}=0.05 \text{ high}=\mathbf{0.25}$ (모델1보다 낮춤) $\text{penalty}=-\mathbf{0.03}$ (모델1보다 강화) $\text{bonus}=\mathbf{0.05}$ (모델1보다 강화)) — "더 쉽게 보너스를 받되, 느리면 더 크게 손해 보게"만 들어 빠른 걸음을 유도하려는 의도로 설계했습니다.

2 설정 근거 & 반복 개선 로드맵

"빨리 클리어 + 안정성"이라는 새로운 이중 평가 축이 도입된 시점에서 시작된 실험입니다.

STEP 0 · 새 목표 도입

"빨리 클리어 + 안정성" 이중 목표 설정

기존까지는 해결률·낙상률만 봤지만, BipedalWalker는 낙상하지 않으면 지형 끝에 도달할 때 에피소드가 종료되는 구조라 비낙상 평균 스텝 수가 "진짜 걷는 속도"를 보여주는 지표라는 점에 착안해 평가 기준에 추가했습니다. 기존 3개 solve

모델의 베이스라인(모델3 477.0 < 모델2 482.3 < 모델1 502.6스텝)을 확인한 뒤, "그렇다면 speed shaping을 더 강하게 밀어붙이면 더 빨라지지 않을까?"라는 가설을 세웠습니다.

ACTION

threshold↓ · bonus↑ · penalty↑ 로 speed shaping 강화

모델2(scratch-initscale ep3081)를 기반으로 threshold를 0.3→0.25로 낮추고(더 쉽게 보너스 구간에 도달), bonus를 0.03→0.05로, penalty를 -0.02→-0.03으로 각각 강화한 파인튜닝을 진행했습니다.

PROBLEM

843ep 만에 학습 중 solve 판정 — 그러나 재평가 결과는 정반대

100ep 재평가 결과: 해결률 **29%**(5개 중 최저), 낙상률 **20%**(5개 중 최고), 비낙상 평균 클리어 스텝 **532.5**(5개 중 최악, 의도와 정반대로 가장 느림). 비낙상 평균 보상도 298.29로 300 문턱에도 못 미쳤습니다. "학습 중 보상이 목표를 넘었다"는 사실이 "의도한 행동을 실제로 얻었다"는 것을 보장하지 않는다는 강력한 반례입니다.

INTERPRETATION

왜 의도와 반대로 갔는가 — 보상 해킹(reward hacking) 가설

threshold를 0.3→0.25로 낮춘 것은 "더 쉽게 보너스를 받게" 하려는 의도였지만, 뒤집어 보면 "무리해서 빠르게 걸을 필요성 자체를 줄이는" 유인 구조이기도 합니다 — 문턱이 낮아진 만큼 약간의 속도만 내도 보너스 조건을 만족하기 때문입니다. penalty를 강화한 것(-0.02→-0.03) 역시 "느리면 손해가 커진다"는 신호지만, 정책이 이를 회피하는 가장 손쉬운 방법은 "빠르게 걷기"가 아니라 "threshold를 살짝만 넘기는 저속·잔진동 패턴을 반복"하는 것이었을 가능성이 높습니다 — 매 스텝의 즉각적 손익만 보는 조건부 보상의 구조적 한계로, 실제로 관찰된 최악의 클리어 속도 (532.5스텝)가 이 해석을 뒷받침합니다. 다만 이 "잔진동" 설명은 속도 histogram과 action trajectory를 직접 확인하지 않았으므로 가설입니다 — 확실히 관찰된 사실은 "공격형 문턱 보상이 의도한 빠른 보행을 만들지 못했다"는 것뿐입니다.

3 학습 곡선 (파인튜닝 843 에피소드)

Reward Curve — g2-si-fastclear-s501 (파인튜닝 구간)

843 에피소드, 최종 avg100=302.46 (학습 중 세이핑 포함 기준)

— episode reward(원시) — avg_reward_100(이동평균) - - - solve 기준선(300)

4 100 에피소드 헤드리스 재평가

noise_std=0, 고정 시드 9000–9099. frame_skip=2·fall_penalty=-10 래퍼는 유지한 채 speed-shaping 보너스만 제외한 wrapper reward 기준입니다(순수 Gymnasium 원점수 아님). "클리어 스텝"은 frame_skip=2 적용 후의 decision step입니다.

지표(100EP 헤드리스, NOISE=0, 세이핑 보너스 제외)	값
전체 평균 보상	272.74
비낙상 평균 보상	298.29
비낙상 표준편차	3.73
해결률 (reward≥300)	29.0%
낙상률	20.0%
비낙상 평균 클리어 스텝	532.5

5 안정성 분석 — 실패의 구조적 원인

주장 1 — 낙상률(20%)이 오히려 가장 높다: 저속·잔진동 패턴은 본질적으로 불안정한 자세를 오래 유지하는 것과 같습니다. 안정적인 정자세로 빠르게 걷기보다, 아슬아슬하게 threshold를 넘나드는 보행을 학습했다면 균형을 잃을 위험이 커지는 것이 당연한 귀결입니다.

주장 2 — 클리어 속도(532.5스텝)가 최악인 것은 "속도 자체를 보상하지 않았기 때문": 이 모델(과 모델1)의 speed shaping은 "일정 속도 이상이면 보너스"라는 문턱 조건이지, "더 빠를수록 더 큰 보너스"라는 연속적 유인이 아닙니다. threshold를 낮추면 그 문턱을 넘기 위해 필요한 노력만 줄어든 뿐, 더 빠르게 걷도록 만드는 직접적 유인은 오히려 약해집니다 — "속도"라는 목표를 직접 보상하지 않고 대리 지표(문턱 통과 여부)로 우회한 설계 자체의 한계로 해석합니다.

향후 방향(제안): 속도 자체를 직접 보상하려면 문턱 조건 대신 스텝당 전진 거리에 비례한 연속 보너스(distance-per-step)를 사용하는 편이 "빠르게 걷기"라는 의도와 더 직접적으로 일치할 것으로 판단됩니다. 이 방향은 본 프로젝트에서는 시간 관계상 시도하지 못했습니다.

6 재현 방법

전제조건	
학습 재현	<code>python3 Bipedalwalker_TD3_live.py --resume --ckpt ep3081 --set run_tag=g2--</code>
권고	
로컬 재생	

